

Bioinformatics Programming Project I (20%)

- จงเขียนโปรแกรมในการเตรียมข้อมูลสำหรับใช้เป็น ข้อมูลเริ่มต้นสำหรับการวิเคราะห์ด้วยซอฟต์แวร์ทางชีวสารสนเทศศาสตร์ ในรูปแบบต่าง ๆ ดังรายละเอียดที่กำหนดให้ ต่อไปนี้
- ข้อมูลเข้า (Input File) ประกอบไปด้วยไฟล์ `all_drug_2023.xml`

○ โครงสร้างไฟล์รูปแบบ XML file format ของไฟล์ `all_drug_2023.xml` มีรายละเอียด ดังนี้

- แต่ละบรรทัดของข้อมูล จะประกอบไปด้วยคำสำคัญ (keyword) และค่าของข้อมูลที่สัมพันธ์กัน (value) แสดงดังตัวอย่างเช่น

```
<drugbank-id primary="true">DB00001</drugbank-id>
```

ความหมาย `<drugbank-id>` คือส่วนของคำสำคัญ และ `DB00001` คือรหัสยา ที่สัมพันธ์กันกับคำสำคัญจากบรรทัดเดียวกัน

- สามารถตรวจสอบข้อมูลรายละเอียดของยา จากฐานข้อมูล DrugBank โดยใช้รหัสยา เช่น `DB00001` ในการค้นหาตัวอย่างข้อมูลที่สัมพันธ์กันกับคำสำคัญจากบรรทัดเดียวกัน เทียบกับในตัวอย่างยาเดียวกัน ในไฟล์ `all_drug_2023.xml` ได้

○ ตัวอย่างรายละเอียดในไฟล์ `all_drug_2023.xml`

```
1 <?xml version="1.0" encoding="UTF-8"?>
2 <drugbank xmlns="http://www.drugbank.ca" xmlns:xsi="http://www.
3 <drug type="biotech" created="2005-06-13" updated="2023-01-03">
4   <drugbank-id primary="true">DB00001</drugbank-id>
5   <drugbank-id>BTD00024</drugbank-id>
6   <drugbank-id>BIOD00024</drugbank-id>
7   <name>Lepirudin</name>
8   <description>Lepirudin is a recombinant hirudin formed by 65
9   &#13;
10  Lepirudin is used as an anticoagulant in patients with heparin-
11   <cas-number>138068-37-8</cas-number>
12   <unii>Y43GF64R34</unii>
13   <state>solid</state>
14   <groups>
15     <group>approved</group>
16     <group>withdrawn</group>
17   </groups>
```

...

- ข้อกำหนดในโครงสร้างของโปรแกรม (Program Instruction)
 - ให้ทำการเขียนโปรแกรม หรือชุดคำสั่งภาษาไพทอน ในการจัดการกับข้อมูล `all_drug_2023.xml` เพื่อสร้างข้อมูลผลลัพธ์ (output file) ให้ตรงกับผลลัพธ์ของแต่ละกลุ่มที่ได้รับ
 - สามารถใช้ชุดคำสั่ง หรือคำสั่งโปรแกรมภาษาไพทอน หลาย ๆ ชุดคำสั่ง ในการช่วยจัดการข้อมูลร่วมกันได้
 - กำหนดให้ใช้ (# หรือ “ ”) ในการอธิบายคำสั่ง ของแต่ละโปรแกรมที่กลุ่มตัวเองได้รับ หรือแต่ละคำสั่งที่ต้องการเพื่อบอกให้ผู้ตรวจสอบทราบ หรือเป็นคำสั่งที่สำคัญที่ต้องการให้รู้เกี่ยวกับข้อมูลของคำสั่งในบรรทัดนั้น ๆ
 - กำหนดให้ประกาศชื่อไฟล์ หรือชื่อตัวแปร ที่สื่อความหมายและเข้าใจได้ง่าย
 - ข้อเสนอแนะในการเขียนโปรแกรมนี้ควรแบ่งการทำงานเป็นชุดคำสั่งย่อย ๆ แยกกัน 2-3 ชุดคำสั่ง เพื่อการจัดการข้อมูลที่มีประสิทธิภาพ
 - ในการสกัดข้อมูลผลลัพธ์ที่ต้องการ ให้พิจารณาความเป็นไปได้ทั้งหมดที่สามารถเกิดขึ้นได้
 - ผลลัพธ์สุดท้ายควรตรวจสอบความถูกต้องของผลลัพธ์ที่ได้เปรียบเทียบกับข้อมูลเข้า ทั้งในส่วนต้น ส่วนกลาง และส่วนปลาย ของข้อมูลและผลลัพธ์เพื่อให้มีความถูกต้องมากที่สุด
- ผลลัพธ์ของแต่ละโปรแกรม (Output File)
 - ผลลัพธ์ของโปรแกรมกลุ่ม 1 (สกัดข้อมูลพื้นฐานของยา และการจัดหมวดหมู่ยา)
 - บันทึกไฟล์ผลลัพธ์ในชื่อ `Drug_Catagory.csv`
 - ข้อมูลส่วน header ของไฟล์ ในแต่ละคอลัมน์ประกอบไปด้วยชื่อ attributes ของ รหัสยา (`DrugBank_ID`), ชื่อสามัญของยา (`Generic_Name`), รูปแบบการรักษา (`Modularity`), สถานะของยา (`Groups`), ระบบการจัดหมวดหมู่ยา ATC ตามมาตรฐานของ WHO (`ATC_codes`) และ รหัส SMILES เรียงตามลำดับเหมือนกับตัวอย่างผลลัพธ์ในไฟล์ `Drug_Catagory.csv` แต่ละคอลัมน์ต้องกันด้วยเครื่องหมาย Comma (,)

■ ตัวอย่างผลลัพธ์ของไฟล์ Drug_Catagory.csv

```

1 DrugBank_ID,Generic_Name,Modularity,Groups,ATC_codes,SMILES
2 DB00001,Lepirudin,biotech,[approved, withdrawn],B01AE02,Nan
3 DB00002,Cetuximab,biotech,[approved],L01FE01,Nan
4 DB00003,Dornase alfa,biotech,[approved],R05CB13,Nan
5 DB00004,Denileukin diftitox,biotech,[approved, investigational],L01XX29,Nan
6 DB00005,Etanercept,biotech,[approved, investigational],L04AB01,Nan
7 ...
8 DB17382,AUM-601,small molecule,[investigational],Nan,Nan
9 DB17383,FN-1501,small molecule,[investigational],Nan,CN1CCN(CC2=CC=C(NC(=O)C3=NNC=C3NC3=C4C=CNC4=NC=N
10 DB17384,Tinengotinib,small molecule,[investigational],Nan,CC1=C2N=C(C3=CC=CC=C3C1)C3=C(NC2=NN1)C=C(N=
11 DB17385,Lipotecan,small molecule,[investigational],Nan,CC[C@@]1(OC(=O)C(C)ON=C2C3=C(C4=C2C=C(C=C4[N+]
12 DB17386,Xenon Xe-129,small molecule,[approved],Nan,[129Xe]
```

○ ผลลัพธ์ของโปรแกรมกลุ่ม 2 (สกัดข้อมูลพื้นฐานของยา และคุณสมบัติของยา)

- บันทึกไฟล์ผลลัพธ์ในชื่อ Drug_Property.csv
- ข้อมูลส่วน header ของไฟล์ ในแต่ละคอลัมน์ประกอบไปด้วยชื่อ attributes ของ รหัสนยา (DrugBank_ID), ชื่อสามัญของยา (Generic_Name), และค่าคุณสมบัติของโมเลกุลที่ได้จากการทำนายเชิงคอมพิวเตอร์ (Predicted_Property) ได้แก่ (logP, logS, Water Solubility, Molecular Weight, Polar Surface Area (PSA), Refractivity, Polarizability, Rotatable Bond Count, H Bond Acceptor Count, H Bond Donor Count, pKa (Strongest Acidic), pKa (Strongest Basic), Physiological Charge, Number of Rings, Bioavailability, Rule of Five, Ghose Filter, MDDR-Like Rule) เรียงตามลำดับเหมือนกับตัวอย่างผลลัพธ์ในไฟล์ Drug_Property.csv แต่ละคอลัมน์ต้องกันด้วยเครื่องหมาย Comma (,) ดังนี้

```
DrugBank_ID,Generic_Name,logP, logS, Water Solubility, Molecular Weight, Polar Surface Area (PSA),Refract
Refractivity, Polarizability, Rotatable Bond Count, H Bond Acceptor Count, H Bond Donor Count,
pKa (Strongest Acidic), pKa (Strongest Basic), Physiological Charge, Number of Rings, Bioavailability,
Rule of Five, Ghose Filter, MDDR-Like Rule
```

■ ตัวอย่างผลลัพธ์ของไฟล์ Drug_Property.csv

```

1 DrugBank_ID,Generic_Name,logP, logS, Water Solubility, Molecular Weight, Polar Surface Area (PSA),Refract
2 DB00001,Lepirudin,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
3 DB00002,Cetuximab,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
4 DB00003,Dornase alfa,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
5 DB00004,Denileukin diftitox,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
6 DB00005,Etanercept,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
7 DB00006,Bivalirudin,-0.76,-4.7,4.64e-02,2180.2853,901.57,543.33,218.54,66,37,28,2.78,11.88,-4,6,0,0,0,1
8 ...
9 DB17382,AUM-601,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
10 DB17383,FN-1501,Nan,Nan,Nan,431.504,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
11 DB17384,Tinengotinib,Nan,Nan,Nan,394.86,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
12 DB17385,Lipotecan,Nan,Nan,Nan,850.71,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
13 DB17386,Xenon Xe-129,Nan,Nan,Nan,128.9048,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan,Nan
```

○ ผลลัพธ์ของโปรแกรมกลุ่ม 3 (สกัดข้อมูลพื้นฐานของยา และเป้าหมายของยา)

- บันทึกไฟล์ผลลัพธ์ในชื่อ Drug_Target.csv
- ข้อมูลส่วน header ของไฟล์ ในแต่ละคอลัมน์ประกอบไปด้วยชื่อ attributes ของ รหัสยา (DrugBank_ID), ชื่อสามัญของยา (Generic_Name), จำนวนเป้าหมายของยาทั้งหมด (Total-Target), จำนวนเอนไซม์ของยาทั้งหมด (Total-Enzyme), จำนวน Ion Chanel ของยาทั้งหมด (Total-IonChanel), จำนวน Transporter ของยาทั้งหมด (Total-Transporter), รายละเอียดโปรตีนของยาทุกตัวเรียงตามลำดับ และแต่ละโปรตีนประกอบไปด้วยคอลัมน์ข้อมูลได้แก่ (protein_number, protein_name, organism, actions, Uniprot_ID, gene_name) เรียงตามลำดับเหมือนกับตัวอย่างผลลัพธ์ในไฟล์ Drug_Target.csv แต่ละคอลัมน์ต้องกันด้วยเครื่องหมาย Comma (,) ดังนี้

```
DrugBank_ID,Generic_Name,Total-Target,Total-Enzyme,Total-IonChannel,Total-Transporter,
[protein_number(1),protein_name,organism,actions,Uniprot_ID,gene_name],
[protein_number(2),protein_name,organism,actions,Uniprot_ID,gene_name],
...,
[protein_number(n),protein_name,organism,actions,Uniprot_ID,gene_name]
```

■ ตัวอย่างผลลัพธ์ของไฟล์ Drug_Target.csv

```
DB000001,Lepirudin,1,0,0,0,[1,Prothrombin,Humans,inhibitor,P00734,F2]
DB000002,Cetuximab,8,0,0,0,[1,Epidermal growth factor receptor,Humans,binder,P00533,EGFR],
[2,Low affinity immunoglobulin gamma Fc region receptor III-B,Humans,binder,O75015,FCGR3B],
[3,Complement C1q subcomponent subunit A,Humans,binder,P02745,C1QA],
[4,Complement C1q subcomponent subunit B,Humans,binder,P02746,C1QB],
[5,Complement C1q subcomponent subunit C,Humans,binder,P02747,C1QC],
[6,Low affinity immunoglobulin gamma Fc region receptor III-A,Humans,binder,P08637,FCGR3A],
[7,High affinity immunoglobulin gamma Fc receptor I,Humans,binder,P12314,FCGR1A],
[8,Low affinity immunoglobulin gamma Fc region receptor II-a,Humans,binder,P12318,FCGR2A]
DB000003,Dornase alfa,1,0,0,0,[1,DNA,Humans,Nan,Nan,Nan]
DB000004,Denileukin diftitox,2,0,0,0,[1,Interleukin-2 receptor subunit alpha,Humans,binder,P01589,IL2RA],
[2,Interleukin-2 receptor subunit beta,Humans,agonist,P14784,IL2RB]
DB000005,Etanercept,9,0,0,0,[1,Tumor necrosis factor,Humans,inhibitor,P01375,TNF],
[2,Lymphotoxin-alpha,Humans,antibody,P01374,LTA],
[3,High affinity immunoglobulin gamma Fc receptor I,Humans,ligand,P12314,FCGR1A],
[4,Low affinity immunoglobulin gamma Fc region receptor II-a,Humans,ligand,P12318,FCGR2A],
[5,Low affinity immunoglobulin gamma Fc region receptor II-b,Humans,ligand,P31994,FCGR2B],
[6,Low affinity immunoglobulin gamma Fc region receptor II-c,Humans,ligand,P31995,FCGR2C],
[7,Low affinity immunoglobulin gamma Fc region receptor III-A,Humans,ligand,P08637,FCGR3A],
[8,Low affinity immunoglobulin gamma Fc region receptor III-B,Humans,ligand,O75015,FCGR3B],
[9,Complement component 1q (C1q),Humans,ligand,P02745,C1QA]
DB000006,Bivalirudin,1,1,0,0,[1,Prothrombin,Humans,inhibitor,P00734,F2],
[1,Myeloperoxidase,Humans,inhibitor,P05164,MPO]
...
DB17382,AUM-601,0,0,0,0
DB17383,FN-1501,0,0,0,0
DB17384,Tinengotinib,0,0,0,0
DB17385,Lipotecan,0,0,0,0
DB17386,Xenon Xe-129,0,0,0,0
```

- เกณฑ์การให้คะแนน 20% (Score rating)

- โครงสร้างของโปรแกรม และชุดคำสั่งที่เขียนขึ้น เป็นระเบียบ อ่านเข้าใจง่าย ใช้วิธีการและฟังก์ชันต่าง ๆ ในการจัดการข้อมูลได้อย่างถูกต้องและเหมาะสม (5%)
- ผลลัพธ์ที่ได้จากการประมวลผลโปรแกรม มีความถูกต้องตามข้อกำหนด รวมไปถึงผลลัพธ์ในการทำงานของคำสั่งภายในโปรแกรมมีความถูกต้องตามหลักการเขียนโปรแกรม (5%)
- สรุปอธิบายตัวโปรแกรม ในส่วนที่สำคัญ ที่พัฒนาขึ้นมาจัดการข้อมูล ไม่เกิน 2 หน้ากระดาษ A4 บันทึกเป็น pdf file ส่งภายในวันอังคารที่ 29 ตุลาคม 2569 ก่อน เที่ยงคืน + โปรแกรมที่พัฒนาขึ้นมานบันทึกเป็น python file (.py) (5%)
- นำเสนอข้อมูลการพัฒนาโปรแกรมกลุ่มละ 20 นาที (นำเสนอ 12 นาที และถามตอบ 8 นาที ต่อกลุ่ม) นำเสนอโปรแกรม ในวันที่ 30 ตุลาคม 2569 เวลา 13.30 – 16.30 น. (5%)