สกัดข้อมูลยาและเป้าหมาย ด้วย Python ไฟล์เดียว

V3: 110 บรรทัด · XML streaming → CSV · ตรวจทวนแยกตอนทดสอบ

1. งานกลุ่ม 3 และผลลัพธ์

อ่าน `all_drug_2023.xml` แล้วสร้าง `Drug_Target.csv` หนึ่งแถวต่อยา มีรหัสยา ชื่อสามัญ และ counts สี่หมวด ตามด้วยรายละเอียดทุก interaction entry ชุดละหกคอลัมน์

```
DrugBank_ID, Generic_Name, Total-Target,
Total-Enzyme, Total-IonChannel, Total-Transporter
[protein_number, protein_name, organism,
actions, Uniprot_ID, gene_name]
```

วงเล็บอยู่ใน cell แรก/สุดท้ายของแต่ละชุด แถวไม่มี entries มี 6 cells และ header ครอบคลุม maximum จริง เริ่ม protein_number ใหม่ที่ 1 ทุกหมวด ข้อมูลหายใช้ Nan หลายค่าคั่นด้วย | โดยคงตำแหน่งคู่ UniProt/gene

2. โครงสร้างโปรแกรมหลัก V3

ส่วนใน v3/group3.py	หน้าที่
text · บรรทัด 17–19	อ่าน tag ลูกตรงแบบ namespace wildcard คืนข้อความ trim หรือสตริงว่าง
iter_rows · บรรทัด 22–70	iterparse/depth เลือก drug ชั้นบนสุด ตรวจ primary/fallback ID และ IDs ซ้ำ สกัดทุก entry แล้ว remove/clear node
export_csv · บรรทัด 73–98	พักแถว CSV บนดิสก์ หาความกว้าง header เขียน UTF-8 BOM แล้ว replace ปลายทางเมื่อเขียนเสร็จ คืนจำนวนยา
CLI · บรรทัด 101–110	รับ --input/--output พิมพ์จำนวนยาและสมมติฐาน; สำเร็จ exit 0, error exit 1, arguments ผิด exit 2

ใช้ standard library บน Python 3.10+ ไม่มี import จาก V1/V2 ไม่มี JSON output และไม่เรียก verifier ระหว่างรัน ต้องมี Python หนึ่งไฟล์กับ XML; 110 รวม comments/docstrings/บรรทัดว่าง ไม่รวม tests/tools/เว็บ

3. วิธีจัดการข้อมูลและเหตุผล

- นับ interaction entries ไม่ใช่จำนวน peptides: DNA อาจไม่มี peptide และ complex อาจมีหลาย subunits
- เก็บทุก actions/UniProt/gene ตามลำดับและ Nan placeholders ไม่ทำให้คู่ค่าเลื่อนเมื่อข้อมูลบางตำแหน่งหาย
- ต้องอ่านครบก่อนทราบ maximum blocks จึงใช้ spool บนดิสก์แทนเก็บทุกยาใน RAM
- CSV เขียนด้วย csv.writer เพื่อรักษา comma/quote/newline และภาษาไทย
- การสกัด/เขียนล้มเหลวก่อน replace ไม่ทับ CSV เดิม การเขียนสำเร็จไม่ได้เป็นผลตรวจอิสระ

V2 มีสองไฟล์ 272 บรรทัดและตรวจอัตโนมัติ V3 แยกงานตรวจออกจาก runtime แต่คงข้อมูล CSV เดิม 110 เป็นฉบับกระชับที่ทดสอบแล้ว ไม่ใช่จำนวนต่ำสุดที่พิสูจน์ว่าลดต่อไม่ได้

ผลตรวจแยกและการใช้งาน

4. หลักฐานการตรวจ V3

27 tests ใน tests/test_v3.py ผ่าน ครอบคลุม golden fixture 5 แถว, numbering, namespace, nested drugs, IDs, Nan/DNA, หลายค่า, CSV escaping และ CLI รวมการคัดลอกเพียง group3.py ไปโฟลเดอร์ว่างแล้วรันแบบ isolated

เครื่องมือ `tools/validate_v3.py` ใช้ตัวอ่าน XML อิสระของ V2 ตรวจทุก cell แล้วสร้าง JSON ระบุ `version=3`, `runtime_verification=false` และ source/CSV hashes เป็นเครื่องมือพัฒนาใน repository ไม่ใช่ dependency ของการรัน V3 รายงานไม่อัปเดตเองเมื่อรัน V3 ใหม่

ข้อมูลจริงจาก XML 1,582,294,735 bytes	ผลตรวจ
จำนวนยา / interaction entries	15,235 / 29,279
targets / enzymes / carriers / transporters	19,344 / 5,683 / 918 / 3,334
polypeptides / complexes / ไม่มี peptide	32,740 / 618 / 336
ตัวอย่างต้น–กลาง–ท้าย	DB00001 / DB08565 / DB17386 ตรงทุก cell
CSV เทียบ V2	เหมือนกันทุกไบต์ SHA-256 ตรงกัน

CSV SHA-256: `7a53dcdf3343c23cc8f14abf52488191a439eaa3fe36418984aa6ef43e78e255`

5. ประสิทธิภาพ V3 บน XML จำลอง

จำนวนยา	ขนาด XML	สกัด/เขียน CSV	Peak RSS
1,000	1.60 MB	0.046 วินาที	17.95 MiB
25,000	39.94 MB	1.137 วินาที	21.05 MiB

วัดด้วย tests/benchmark_v3.py เฉพาะตัวสกัด ไม่รวม verifier ต่างจาก benchmark V2 ที่รวมการตรวจ ข้อมูลจำลองไม่มี complexes ไม่ใช้แทนเวลา/RAM ของ XML จริง หน่วยความจำขึ้นกับยาที่ใหญ่ที่สุด parser buffer และชุด IDs

6. วิธีใช้และสิ่งที่ส่ง

```
python3 -m venv .venv
source .venv/bin/activate
python v3/group3.py
```

วาง XML ใน root ได้ v3/Drug_Target.csv ใช้ --input/--output เปลี่ยนพาธได้ ถ้าดาวน์โหลดเฉพาะ group3.py ให้วางกับ XML แล้ว cd เข้าโฟลเดอร์ก่อนรัน ส่ง source .py และ PDF สรุปสองหน้า พร้อม CSV ตามช่องทางผู้สอน บทความละเอียดแยก docs/article_v3.md นำเสนอ 12 นาที ถามตอบ 8 นาที

7. ข้อกำกวมและความต่างจากภาพ

> **Total-IonChannel:** ยังคงนับ carriers ตามสมมติฐานของ V2 ซึ่งไม่ใช่ ion channels ทางชีววิทยา ต้องยืนยันนิยามกับผู้สอน การตรวจผ่านยืนยันข้อมูลตามนโยบายนี้ ไม่รับรองความตรงเจตนาโจทย์ 100%

DB00004 มี 3 targets ตาม XML แม้ภาพมี 2; Etanercept มี TNF actions สองค่าและ C1q UniProt/gene 3 คู่ DB00006 counts 1,1,0,0 ตรงทั้งภาพและ XML และเริ่มเลข 1 ใหม่ทั้ง target/enzyme

อ้างอิง: โจทย์หน้า 1–5; docs/test_results.txt; v3/Drug_Target.validation.json; docs/benchmark_results.json ฉบับ V2/V1 เก็บแยกใน docs/v2/ และ docs/v1/