

การสกัดข้อมูลยา และเป้าหมายจาก DrugBank XML

รายงานสรุปโปรแกรม Python ที่รันใน venv และตรวจสอบข้อมูลต้นทาง

1. วัตถุประสงค์และผลลัพธ์

อ่าน all_drug_2023.xml เป็นค่าเริ่มต้นตามโจทย์ สร้าง Drug_Target.csv หนึ่งรายการต่อหนึ่งยา มีรหัส ชื่อสามัญ counts ของ targets, enzymes, IonChannel และ transporters แล้วตามด้วยรายละเอียดทุก interaction entry ชุดละ 6 คอลัมน์:

```
protein_number, protein_name, organism,  
actions, Uniprot_ID, gene_name
```

รูปแบบหลักใช้วงเล็บเหลี่ยมครอบแต่ละชุดตามภาพโจทย์และแถวที่ไม่มีเป้าหมายจบที่ 6 คอลัมน์ header ครอบคลุมจำนวนชุดสูงสุดในข้อมูล มีรูปแบบตารางเสริมสำหรับการวิเคราะห์ที่เติมช่องว่างให้ทุกแถวเท่ากัน

2. โครงสร้าง 3 ขั้นตอน: อ่าน → เขียน → ตรวจสอบ

ไฟล์	การทำงานสำคัญ
drugbank_parser.py	ใช้ ElementTree.iterparse อ่านทีละยา ส่องรับ namespace เลือกรหัส primary และสกัด 4 หมวด จากนั้นนำ node ออกจาก root เพื่อคืนหน่วยความจำ
group3.py	พักข้อมูลใน spool บนดิสก์เพื่อทราบจำนวนชุดสูงสุด เขียนด้วย csv.writer เป็น UTF-8 BOM ตรวจสอบก่อนแทนที่ไฟล์ CSV เดิม และสร้างรายงาน JSON
verify_output.py	อ่าน XML ซ้ำด้วยตรรกะอิสระ ไม่เรียกตัวสกัด เทียบทุก cell ทุกแถว พร้อมเก็บตัวอย่างต้น/กลาง/ท้ายและ SHA-256 ของไฟล์

สร้าง .venv ด้วย Python 3.14.4 และใช้ standard library จึงไม่มี dependencies ภายนอก มี comments/docstrings ภาษาไทย และข้อพึงกัชั้น/ตัวแปรที่สื่อความหมายตามข้อกำหนด

3. หลักการสกัดและจัดการกรณีพิเศษ

- XML ับ entry ใน targets → enzymes → carriers → transporters และเรียงตามลำดับ XML ภายในหมวด protein_number เริ่ม 1 ใหม่ทุกหมวดภายในแต่ละยา ไม่ตัดโปรตีนที่ซ้ำแต่ทำหน้าที่ต่างกันออก
- ใช้ชื่อและ organism ของ entry ก่อน; UniProt ใช้ attribute id ของ polypeptide และ gene ใช้ gene-name ไม่ใช้รหัส BE ของ target เป็น UniProt
- ไม่มีข้อมูลใส่ Nan ตามโจทย์ ยังเก็บ non-protein target เช่น DNA คลาย actions หรือ polypeptides คั่นด้วย | โดยรักษาคู่ ID/gene และตำแหน่งที่หาย; JSON เก็บชื่อ/organism ของทุก subunit ใน complexes
- เลือก drug ชั้นบนสุดและใช้ namespace-aware parser ไม่เอา drug ใน pathways มานับเพิ่ม XML ขาดตอน รหัสหาย/กำกับ/ซ้ำ ให้หยุดพร้อมข้อความผิดพลาด

การทดสอบและสถานะงาน

4. หลักฐานการทดสอบ

ผ่าน **66 automated tests** ใน `.venv` รวม namespace, primary IDs, missing data, หลาย polypeptides/actions, CSV และ CLI มี fixture 11 ยาและ golden 5 แยกจากภาพจอทียืนยันค่าเริ่มต้น XML, header ตามภาพ และการเริ่มเลขใหม่ทุกหมวดตาม Bivalirudin

กลุ่มทดสอบ	สิ่งที่ยืนยัน
โครงสร้างต้นทาง	XML namespaces, primary IDs, nested drug, 4 หมวด, empty entries และการเรียงรายละเอียดโปรตีน
ความครบของข้อมูล	DNA ไม่มี polypeptide, หลาย actions, หลาย polypeptides, คู่ ID/gene ที่มีข้อมูลหาย และโปรตีนหลายทบทาง
CSV และการตรวจสอบ	comma/quote/newline/ภาษาไทย, รูปแบบหลักและตาราง, การตรวจจับค่าถูกแก้ แยกหาย แยกเกิน ลำดับผิด และ header ผิด
ความผิดพลาดและ CLI	XML ขาดตอน/ไม่ใช่ XML, ไม่มี input, ID กำกวม/ซ้ำ, พารเซนกัน และการรักษาไฟล์เดิมเมื่อสกิดไม่สำเร็จ

XML จริงขนาด **1.58 GB** ระบุ exported-on 2023-01-04 สกิดได้ **15,235 ยา / 29,279 entries** ตัวตรวจอิสระเทียบทุก cell ทุกแถวผ่าน (status=passed) ตัวอย่างต้น/กลาง/ท้ายคือ DB00001, DB08565 และ DB17386 พร้อม SHA-256 และพาร Python ใน venv

5. ประสิทธิภาพโหมด XML บนข้อมูลจำลอง

จำนวนยา	ขนาด XML	สกิด + ตรวจสอบ	Peak RAM
1,000	1.60 MB	0.220 วินาที	23.93 MiB
25,000	39.94 MB	3.792 วินาที	26.42 MiB

วัดใน process แยกบน Linux เครื่องนี้ ผลทั้งสองชุดผ่านการเทียบ XML/CSV ทุกแถว RAM ขึ้นกับยาตัวใหญ่ที่สุด parser buffer ชุด ID ที่ตรวจซ้ำ 3 แถว ตัวอย่าง และรายละเอียด complexes ในรายงาน spool อยู่บนดิสก์ ชุดจำลองนี้ไม่มี complexes; ผลนี้ไม่ใช่เวลาหรือ RAM ของฐานจริงปี 2023

6. จุดคำถามที่ต้องยืนยันกับผู้สอน

Total-IonChannel: สมมติให้คอลัมน์นี้นับ carriers ตามลำดับ 4 หมวด และเปิดเผยในโค้ด/ข้อความขณะรัน/JSON carriers ไม่ใช่คำพ้องกับ ion channels ทางชีววิทยา จึงยังต้องยืนยันนิยามคอลัมน์กับผู้สอน แม้ค่าที่เขียนตรงกับ XML

ภาพกับ XML ต่างกัน: DB00004 มี 3 targets ใน XML จริง แต่ภาพแสดง 2 DB00006 ยืนยันจาก XML ได้ counts 1,1,0,0 ต่างจากภาพ 1,1,0,1 และ C1q ของ Etanercept มี UniProt/gene 3 คู่ โปรแกรมรักษาทุกค่าจาก XML

7. วิธีใช้และสิ่งที่ยังต้องดำเนินการ

```
source .venv/bin/activate
python group3.py
python -m unittest discover -v
```

ผล XML ปัจจุบัน: targets 19,344; enzymes 5,683; carriers 918; transporters 3,334 รวม 29,279 entries มีสูงสุด 304 blocks ต่อหนึ่งยา ผลใน root มาจาก XML จริง และผล TXT เดิมเก็บแยกใน examples/text_recovery/

อ้างอิง: Bioinformatics Programming Project I.pdf หน้า 1–5; DrugBank XML Format Reference; หลักฐานใน docs/test_results.txt และ docs/benchmark_results.json