สกัดข้อมูลยาและเป้าหมาย ด้วย Python สองไฟล์

V2: 272 บรรทัด · อ่าน XML แบบ streaming · ตรวจทุก cell ทุกแถว

1. วัตถุประสงค์และผลลัพธ์ตามโจทย์

อ่าน `all_drug_2023.xml` แล้วสร้าง `Drug_Target.csv` หนึ่งแถวต่อยา มี DrugBank_ID, Generic_Name, Total-Target, Total-Enzyme, Total-IonChannel และ Total-Transporter ตามด้วยรายละเอียดทุก interaction entry ชุดละหกคอลัมน์:

```
protein_number, protein_name, organism,
actions, Uniprot_ID, gene_name
```

รูปแบบหลักคง [และ] ครอบหก CSV cells ตามภาพโจทย์ header ครอบคลุม maximum ที่พบจริง แถวไม่มี entries จบที่หก cells ข้อมูลหายใช้ Nan และ protein_number เริ่มใหม่ทุกหมวด

2. โครงสร้าง Version 2 — สองไฟล์หลัก

ไฟล์ / บรรทัดรวม	หน้าที่และฟังก์ชันสำคัญ
`v2/group3.py` 131 บรรทัด	text อ่านลูกตรง; iter_rows ใช้ iterparse และ depth เลือก drug ชั้นบนสุด export_csv พัก JSONL บนดิสก์ สร้าง header/CSV แล้วเรียกตัวตรวจ; main รับ --input/--output
`v2/verify_output.py` 141 บรรทัด	reference_rows อ่าน XML อิสระด้วย stack ไม่ import exporter verify_csv เทียบทุก cell และเก็บ audit/samples; sha256_file อ่านเป็น chunks; main รับ --input/--csv

รวม 272 บรรทัด ลดจาก V1 สามไฟล์ 652 บรรทัดประมาณ 58.3% ตัด TXT, table layout และ dataclasses ยังคงการตรวจทุกแถวและ complex metadata จึงมากกว่า prototype 163 บรรทัดที่ตรวจเพียงสามตำแหน่ง จำนวนบรรทัดรวม comments/blank lines ไม่รวม tests เว็บไซต์ หรือเอกสาร

3. หลักการสกัดและกรณีพิเศษ

- ใช้ namespace wildcard และ direct children เลือก primary ID; fallback เฉพาะ DB ID เดียวที่ไม่กำกวม ตรวจ ID หาย/ผิด/ซ้ำ และไม่เอา nested drug ใน pathways มานับเพิ่ม
- นับ entries ใน targets → enzymes → carriers → transporters รวม DNA ไม่มี polypeptide รักษาลำดับ XML ไม่ sort position และไม่ deduplicate ข้ามบทบาท
- ชื่อ/organism ระดับ entry มาก่อน polypeptide; UniProt ใช้ attribute id ไม่ใช่ BE ID หลาย actions/peptides คั่นด้วย | พร้อม Nan placeholders เพื่อรักษาคู่ ID/gene
- UTF-8 BOM กับ csv.writer รักษา comma, quote, newline และภาษาไทย; JSON เก็บทุก subunit ของ complexes

Python 3.10 ขึ้นไป ใช้ standard library; environment ที่ทดสอบคือ .venv Python 3.14.4 วางสอง .py กับ XML ในโฟลเดอร์เดียวกันก็รันได้ ไม่ต้องมี V1 หรือเว็บไซต์

ผลการตรวจสอบและการใช้งาน

4. การทดสอบของ V2

27 tests ของ tests/test_v2.py ผ่าน รวม golden 5 แถวจากภาพ PDF, namespace, primary/fallback IDs, nested drugs, DNA/Nan, หลายค่าและข้อมูลที่มี comma/quote/newline/ภาษาไทย

หลักฐาน	สิ่งที่ยืนยัน
Golden และ numbering	fixture 11 ยา; Bivalirudin ใช้เลข 1 ทั้ง target และ enzyme ตามภาพ และ counts ตาม XML
Mutation / independent check	ตรวจจับ cell ที่ผิดในแถวที่ไม่ใช่ samples, counts/header/numbering, แถวหาย/เกิน/สลับ
การรันและข้อผิดพลาด	คัดลอกสอง .py ไปโฟลเดอร์เปล่าแล้วรันได้; Python -O ยังตรวจได้; malformed XML/พาธชน/validation ล้มเหลวรักษาผลเดิมก่อน replace

XML จริง **1,582,294,735 bytes** version 5.1 exported-on 2023-01-04 ให้ผล **15,235 ยา / 29,279 entries** ทุก cell ตรวจผ่าน ต้น DB00001 กลาง DB08565 ท้าย DB17386 counts รวม targets 19,344; enzymes 5,683; carriers 918; transporters 3,334

พบ polypeptides 32,740 records และ 618 complexes รายงาน V2 เก็บทุก subunit พร้อม hashes และ version=2 CSV V2 มี SHA-256 เหมือนผล V1 ทุก byte แต่สร้างและตรวจด้วยสองไฟล์ V2 เอง

5. ประสิทธิภาพ V2 บน XML จำลอง

จำนวนยา	ขนาด XML	สกัด + ตรวจครบ	Peak RSS
1,000	1.60 MB	0.111 วินาที	23.60 MiB
25,000	39.94 MB	2.535 วินาที	25.85 MiB

วัดใหม่ด้วย tests/benchmark_v2.py ใน process แยก ชุดจำลองไม่มี complexes ไม่ใช่เวลา/RAM ของ XML จริง RAM ขึ้นกับยาตัวใหญ่ที่สุด parser buffer ชุด IDs samples และ complex metadata; spool ใช้พื้นที่ดิสก์

6. วิธีรันและสิ่งที่ส่ง

```
.venv/bin/python v2/group3.py
.venv/bin/python v2/verify_output.py
.venv/bin/python -m unittest tests.test_v2 -v
```

วาง XML ใน root แล้วได้ v2/Drug_Target.csv และ v2/Drug_Target.validation.json; เปลี่ยนพาธด้วย --input/--output ส่ง Python สองไฟล์และ PDF สรุปสองหน้า พร้อม CSV ตามช่องทางผู้สอน บทความละเอียดแยกใน docs/article_v2.md นำเสนอ 12 นาที ถามตอบ 8 นาที

7. ขอบเขตและข้อกำกวม

> **Total-IonChannel:** ยังคง mapping ไป carriers ตามสมมติฐานเดิม ซึ่งไม่ใช่ ion channels ทางชีววิทยา ต้องยืนยันนิยามกับผู้สอน จึงแยก verification_status=passed จาก specification_status=requires_ion_channel_definition

ต่างจากภาพ: DB00004 มี 3 targets; Etanercept มี TNF actions สองค่าและ C1q UniProt/gene 3 คู่ DB00006 มี counts 1,1,0,0 ตรงกันทั้งภาพและ XML CSV/JSON replace ทีละไฟล์ ไม่ใช่ transaction รวม หากรายงาน replace ล้มเหลวหลัง CSV สำเร็จต้องตรวจ hashes ของคู่ไฟล์

อ้างอิง: โจทย์หน้า 1–5; docs/test_results.txt; v2/Drug_Target.validation.json; docs/benchmark_results.json เอกสาร V1 เก็บใน docs/v1/ และไม่ใช่คำสั่งเริ่มต้นของ V2