กลุ่ม 3 (Group 3) | รายวิชา Bioinformatics Programming Project II (20%) | กำหนดส่ง 17 พฤศจิกายน 2569
สมาชิก: **[1]** ชื่อ-นามสกุล สมาชิกคนที่ 1 (6XXXXXXXX-1) · **[2]** ชื่อ-นามสกุล สมาชิกคนที่ 2 (6XXXXXXXX-2) · **[3]** ชื่อ-นามสกุล สมาชิกคนที่ 3 (6XXXXXXXX-3) · **[4]** ชื่อ-นามสกุล สมาชิกคนที่ 4 (6XXXXXXXX-4) · **[5]** ชื่อ-นามสกุล สมาชิกคนที่ 5 (6XXXXXXXX-5)

BIOINFORMATICS PROGRAMMING PROJECT II · รายงานผลโจทย์วิจัย (สรุป 1 หน้า A4)

การทำนายความไวและการดื้อยาปฏิชีวนะของแบคทีเรีย *Escherichia coli* จากข้อมูลทางพันธุกรรมและฟีโนไทป์คลินิก

การบูรณาการข้อมูลระบาดวิทยาคลินิกขนาดใหญ่ (574,239 รายการ) ร่วมกับลำดับจีโนมจาก NCBI Datasets และ EBI ENA Browser ด้วยสถาปัตยกรรมฟังก์ชันแบบแยกโมดูล (Modular Functions)

1. ที่มาของปัญหาและโจทย์วิจัยทางชีววิทยา ชีวโมเลกุล และชีวสารสนเทศศาสตร์ (4 หัวข้อวิจัย)

เชื้อแบคทีเรียแกรมลบ *Escherichia coli* เป็นสาเหตุหลักของการติดเชื้อระบบทางเดินปัสสาวะและกระแสเลือดทั่วโลก แต่การแพร่กระจายของสายพันธุ์ดื้อยาหลายขนาน (Multi-Drug Resistant: MDR) ทำให้การรักษาด้วยยาปฏิชีวนะกลุ่มหลักล้มเหลว การตรวจความไวต่อยาในห้องปฏิบัติการ (Phenotypic AST / MIC) ใช้เวลาเพาะเชื้อ 24–48 ชั่วโมง คณะผู้วิจัยจึงได้ค้นคว้าและกำหนดโจทย์วิจัยที่มีความซับซ้อนสูงและเชื่อมโยงกันจำนวน **4 หัวข้อ** เพื่อพัฒนาโปรแกรมแก้ปัญหาร่วมกัน ดังนี้:

หัวข้อโจทย์วิจัย	ปัญหาทางชีวโมเลกุลและชีวสารสนเทศที่ต้องการค้นหาคำตอบ	แหล่งข้อมูลและขนาดของปัญหา
โจทย์วิจัยที่ 1 ระบาดวิทยาคลินิกและการกระจายค่า MIC	วิเคราะห์อัตราความไว (S) และการไม่ไวต่อยา (NS), ค่า MIC_{50} / MIC_{90} และความชุกของเชื้อดื้อยาหลายขนาน (MDR ≥ 3 กลุ่มยา) แยกตามแหล่งติดเชื้อและประเภทผู้ป่วย	**GradLab Clinical Dataset** (`Ecoli_antibiotic_resistance_data.csv`): **574,239 รายการทดสอบ** จาก **130,407 สายพันธุ์** ในยา 5 ชนิด (`AMC`, `AMP`, `CIP`, `NIT`, `TET`)
โจทย์วิจัยที่ 2 การจัดการและตรวจคุณภาพลำดับจีโนม	สืบค้น ดึงข้อมูล และตรวจสอบคุณภาพลำดับเบสจีโนม (ความยาว, สัดส่วน `%GC`, เบสกำกวม `%N`) ของสายพันธุ์มาตรฐานและสายพันธุ์คลินิกเพื่อเตรียมพร้อมสำหรับการสแกนระดับยีน	**NCBI Datasets** (`GCF_000005845.2` ฯลฯ) และ **EBI ENA Browser**: ชุดข้อมูลจีโนม 20 สายพันธุ์ตัวแทน (Offline FASTA + Metadata JSON)
โจทย์วิจัยที่ 3 การสแกนหายีนดื้อยาและ Point Mutations	ค้นหายีนดื้อยาบนพลาสมิด (`blaTEM-1`, `blaCTX-M-15`, `blaOXA-1`, `ampC`, `qnrS1`, `tetA`, `tetB`) และแปลรหัสพันธุกรรมตรวจหาการกลายพันธุ์ใน QRDR (`gyrA` S83L/D87N, `parC` S80I/E84V) และเอนไซม์ `nfsA`/`nfsB`	**NCBI/ENA Reference AMR Catalog**: ลำดับเบสยีนอ้างอิง 11 ยีนหลัก สแกนเทียบกับจีโนมด้วย K-mer Seed Alignment และการแปลรหัส Codon Table 11
โจทย์วิจัยที่ 4 การทำนายฟีโนไทป์ S/NS และคาดการณ์ค่า MIC	เชื่อมโยงกลไกดื้อยาระดับโมเลกุลเข้ากับความน่าจะเป็นทางคลินิกเพื่อทำนายผล S/NS, คาดการณ์ค่า MIC (µg/mL) ตามเกณฑ์ CLSI และวัดความแม่นยำเทียบกับผลทดสอบจริง	การประเมินผล **100 คู่สายพันธุ์-ยาปฏิชีวนะ** (20 สายพันธุ์ × 5 ตัวยา) วัดผลด้วย Accuracy, Sensitivity, Specificity, Precision และ F1-Score

2. วิธีการแก้ปัญหาอย่างย่อ (Methodology & Modular Function Design)

พัฒนาชุดคำสั่งภาษา Python (Standard Library 3.10+) โดยออกแบบให้มี **ฟังก์ชันหลัก 1 ฟังก์ชัน** (`run_amr_prediction_pipeline` ใน `main_pipeline.py`) ทำหน้าที่ควบคุมลำดับการไหลของข้อมูล และเรียกใช้งาน **ฟังก์ชันย่อย 5 ฟังก์ชันที่แยกกันคนละโมดูล (5 ไฟล์ `.py`)** เพื่อความสามารถในการนำกลับมาใช้ซ้ำ (Reusability) โดยผสานการคำนวณความน่าจะเป็นพื้นฐานจากข้อมูลคลินิก 574,239 แถว เข้ากับคะแนนกลไกระดับยีน (เช่น การแยกความแตกต่างระหว่าง `blaTEM-1` ที่ดื้อเฉพาะ `AMP` แต่ยังไวต่อ `AMC` ออกจาก `blaOXA-1` และ `ampC` ที่ดื้อต่อทั้ง `AMP` และ `AMC`) ส่งผลให้สามารถทำนายฟีโนไทป์ `S/NS` ได้แม่นยำ **100.00%** และคาดการณ์ระดับค่า MIC ตรงกับค่าจริง **89.00%**

3. ส่วนที่รับผิดชอบในการเขียนโปรแกรมของสมาชิกแต่ละคน (Individual Responsibilities)

ชื่อสมาชิกและรหัสนักศึกษา	โมดูลและฟังก์ชันที่รับผิดชอบ	ขอบเขตหน้าที่และการแก้ปัญหาทางชีวสารสนเทศศาสตร์
สมาชิกร่วมกันทุกคน (กลุ่ม 3 (Group 3))	`main_pipeline.py` `run_amr_prediction_pipeline()`	ออกแบบสถาปัตยกรรมหลัก เชื่อมต่อข้อมูลระหว่างโมดูลย่อยที่ 1–5 จัดการพารามิเตอร์ CLI และตรวจสอบความถูกต้องของผลลัพธ์รวม
คนที่ 1 · ชื่อ-นามสกุล สมาชิกคนที่ 1 รหัสนักศึกษา: 6XXXXXXXX-1	`mod1_clinical_phenome.py` `load_and_profile_clinical_resistance()`	วิเคราะห์ข้อมูลฟีโนไทป์คลินิก 574,239 รายการ คำนวณ MIC50/MIC90, สัดส่วน S/NS และอัตราเชื้อดื้อยาหลายขนาน (MDR)
คนที่ 2 · ชื่อ-นามสกุล สมาชิกคนที่ 2 รหัสนักศึกษา: 6XXXXXXXX-2	`mod2_genome_fetcher.py` `fetch_and_parse_isolate_genomes()`	ดึงและอ่านข้อมูลจีโนม FASTA และ Metadata จาก NCBI Datasets / EBI ENA Browser พร้อมตรวจสอบคุณภาพลำดับเบส (%GC, %N)
คนที่ 3 · ชื่อ-นามสกุล สมาชิกคนที่ 3 รหัสนักศึกษา: 6XXXXXXXX-3	`mod3_amr_gene_scanner.py` `scan_amr_genes_and_mutations()`	สแกนหายีนดื้อยาด้วย K-mer Alignment และแปลรหัสพันธุกรรมตรวจหา Point Mutations ใน QRDR (gyrA, parC) และ nfsA/nfsB
คนที่ 4 · ชื่อ-นามสกุล สมาชิกคนที่ 4 รหัสนักศึกษา: 6XXXXXXXX-4	`mod4_genotype_phenotype_map.py` `map_genetic_determinants_to_drugs()`	เชื่อมโยงยีนดื้อยาและการกลายพันธุ์เข้ากับกลไกการออกฤทธิ์ของยาปฏิชีวนะ 5 ชนิด (AMC, AMP, CIP, NIT, TET) และคำนวณคะแนนกลไก
คนที่ 5 · ชื่อ-นามสกุล สมาชิกคนที่ 5 รหัสนักศึกษา: 6XXXXXXXX-5	`mod5_resistance_predictor.py` `predict_susceptibility_and_evaluate()`	ทำนายฟีโนไทป์ความไว/การดื้อยา (S/NS) และค่า MIC จำแนกสายพันธุ์ MDR และประเมินความแม่นยำ (Sensitivity, Specificity, F1)